

Slajd tytułowy

Improving EEG classification of alcoholic and control subjects using DWT-CNN-BiGRU with various noise filtering techniques

0 artykuły

- Autorzy: Nidhi [\[nidi\]](#) Patel, Jaiprakash [\[Dżaprakas\]](#) Verma, Swati Jain [\[Słati Dżan\]](#)
- Nirma University, India
- Data wydania: 19 sierpnia 2025
- Opublikowany w: Frontiers in Neuroinformatics

Problemy

- Obecny sposób diagnozowania alkoholizmu opiera się o subiektywną opinię
- Sygnały EEG są podatne na zakłócenia i trudne w analizie

Sygnały mózgowe są bardzo słabe (microvolty), podatne na zakłócenia: ruchy oczu, mruganie, sieć elektryczna

Rozwiązanie

Zastosowanie nowatorskiego modelu DWT-CNN-BiGRU

Podział nazwy na 3 elementy

Metody filtrujące

Eksperyment badał zastosowanie 3 metod filtrujących dane z EEG

Discrete oznacza że pracują na próbkach danych

DCT

DCT przedstawia sygnał za pomocą sumy cosinusów o różnych częstotliwościach.

Bardzo wydajna funkcja, koncentruje sygnał do niewielkiej ilości mających znaczenie współczynników, używa tylko liczb rzeczywistych.

Następnie odseparowane zostają komponenty o wysokiej częstotliwości, a dane są odtwarzane używając funkcji odwrotnej - IDCT.

DFT

DFT przekształca sygnał na sumę zespolonych fal sinusoidalnych o różnych częstotliwościach, amplitudach i fazach.

Tutaj robi się bardziej skomplikowanie bo wchodzimy w rejony liczb zespolonych.

DWT

DWT jest jeszcze ciekawsze od DCT i DFT. Dane są przepuszczane kilkakrotnie przez powiązane ze sobą filtry dolno i górno przepustowe, dając współczynniki detali i współczynniki aproksymacji.

W badaniu użyto 4 poziomowego DWT, współczynniki detali są poddawane miękkemu progowaniu.

Sygnał jest odtwarzany przez odwrócenie DWT

Modele

Uczone na bazie danych Kaggle

BiLSTM

Budowa:

- Pierwsza warstwa kowolucyjna 1D - 64 filtry - Ekstrahuje lokalne cechy przestrzenne z sygnałów EEG, takie jak wzorce aktywności w obrębie kanałów. Niewielka liczba filtrów pozwala uchwycić podstawowe zależności w danych.
- Pierwsza warstwa MaxPooling1D - Redukuje wymiarowość cech oraz zmniejsza złożoność obliczeniową modelu, zachowując najistotniejsze informacje.
- Druga warstwa konwolucyjna 1D - 128 filtrów - Uczy się bardziej złożonych i abstrakcyjnych reprezentacji przestrzennych sygnału EEG, bazując na cechach wyodrębnionych wcześniej.
- Druga warstwa MaxPooling1D - Dalsza redukcja rozmiaru danych oraz zwiększenie odporności modelu na szum i drobne przesunięcia w sygnale.
- Trzecia warstwa konwolucyjna 1D - 128 filtrów - Pogłębia ekstrakcję cech, umożliwiając identyfikację wysokopoziomowych wzorców przestrzennych charakterystycznych dla sygnałów EEG.
- Trzecia warstwa MaxPooling1D - Ostatecznie kompresuje reprezentację cech przed przekazaniem ich do części sekwencyjnej modelu.

- Pierwsza dwukierunkowa warstwa LSTM - BiLSTM - Analizuje sekwencje czasowe cech w obu kierunkach (przód-tył), zachowując pełną strukturę czasową. Umożliwia uchwycenie zależności zarówno wcześniejszych, jak i późniejszych fragmentów sygnału EEG.
- Druga dwukierunkowa warstwa LSTM - BiLSTM - Agreguje informacje czasowe z całej sekwencji w jedną reprezentację, koncentrując się na najistotniejszych zależnościach temporalnych.
- Warstwa gęsta (Dense) z aktywacją Softmax - Pełni funkcję klasyfikatora. Przekształca wyuczoną reprezentację w rozkład prawdopodobieństw przypisania próbki EEG do poszczególnych klas.
- Warstwy Dropout - Stosowane po wybranych warstwach konwolucyjnych oraz po każdej warstwie LSTM. Losowo dezaktywują neurony podczas uczenia, co ogranicza przeuczenie i poprawia zdolność uogólniania modelu.

BiGRU

Model jest bardzo podobny do modelu BiLSTM, ale warstwy LSTM zostały zastąpione warstwami GRU. Po każdej warstwie konwolucyjnej dodano także warstwę dropout.

Użycie warstwy GRU redukuje złożoność obliczeniową z jednoczesnym zachowaniem modelowania złożoności czasowych.

Setup testowy

Z obrazka

Badani

W badaniu uczestniczyło 16 osób, użyto 64 elektrod na pacjenta, częstotliwość próbkowania 256Hz, 30 badań po 1 sekundzie, bodźce pojedyncze i sparowane

Wyniki

CNN-BiLSTM - 93% dokładności

CNN-BiGRU - 94% dokładności

Wyniki sugerują, że prostsza architektura i mniejsza ilość parametrów wpływają na bardziej wydajne uczenie się w przypadku modelu CNN-BiGRU.

Przyszłość

Uzyskanie większej ilości danych z EEG